

1. Datos de Educación

“Sistema de alerta temprana en primer año universitario”

Una universidad pública ha detectado que más del 35% de sus estudiantes de primer año reprueba al menos un curso crítico, lo que impacta directamente en la deserción durante el primer año. Para enfrentar este problema, se ha implementado un sistema piloto de Learning Analytics en cursos masivos, integrando datos del LMS, evaluaciones y encuestas de autorregulación.

El equipo académico busca pasar de un enfoque reactivo a uno preventivo, identificando tempranamente estudiantes en riesgo. Sin embargo, no existe una tipología clara de estudiantes: algunos asisten pero no rinden, otros estudian poco pero aprueban, y otros muestran patrones inconsistentes.

Los datos recopilados son los siguientes:

Variable	Tipo	Unidad	Descripción
horas	numérica	horas/día	Tiempo promedio diario dedicado al estudio (obtenido a través de encuesta de percepción)
asistencia	numérica	% (0–100)	Porcentaje de asistencia a clases
tareas	numérica	% (0–100)	Porcentaje de tareas entregadas
retrasos	numérica	conteo	Número de entregas tardías
planificacion	numérica	escala 1–5	Nivel de planificación del estudio (obtenido a través de encuesta de percepción)
nota_final	numérica	escala 1–7	Calificación final del curso
aprobado	categorica (binaria)	0/1	Estado de aprobación (≥ 4.0)

2. Datos de Salud:

“Priorización de pacientes en atención primaria”

Un centro de salud familiar enfrenta una alta demanda de pacientes con enfermedades crónicas. Los recursos son limitados, y los equipos médicos necesitan priorizar a quienes presentan mayor riesgo cardiovascular.

Se ha comenzado a sistematizar información clínica y conductual de los pacientes, pero no existe una segmentación clara. Algunos pacientes presentan buenos indicadores clínicos pero malos hábitos, mientras que otros tienen factores de riesgo invisibles en los datos.

Los datos recopilados son los siguientes:

Variable	Tipo	Unidad	Descripción
imc	numérica	kg/m ²	Índice de masa corporal
presion	numérica	mmHg	Presión arterial sistólica
actividad	numérica	horas/semana	Nivel de actividad física
colesterol	numérica	mg/dL	Nivel de colesterol total
riesgo	numérica	índice (adimensional)	Puntaje continuo de riesgo
riesgo_alto	categoría (binaria)	True/False	Riesgo alto (percentil >60)

3. Datos de Movilidad

“Planificación de transporte en ciudad intermedia”

Una ciudad intermedia enfrenta crecientes problemas de congestión, tiempos de viaje elevados y desigualdad en el acceso al transporte. El municipio ha recolectado datos de movilidad mediante encuestas y sensores urbanos. Sin embargo, los datos presentan problemas típicos como lo son errores en el reporte del modo de transporte, inconsistencias y registros incompletos.

El objetivo es comprender cómo se mueven las personas en la ciudad para diseñar políticas de transporte más eficientes y sostenibles.

Los datos recopilados son los siguientes:

Variable	Tipo	Unidad	Descripción
viajes	numérica	viajes/día	Número de viajes diarios
distancia	numérica	km	Distancia promedio por viaje
tiempo	numérica	minutos	Tiempo promedio por viaje
modo_transporte	categoría	categoría	Medio principal (auto, bus, bicicleta, caminar)
congestion	numérica	índice (km·min)	Indicador de carga de movilidad (distancia × tiempo)
alta_congestion	categoría (binaria)	True/False	Alta congestión (percentil >65)

4. Datos de comercio

“Estrategia de personalización en e-commerce”

Una empresa de comercio electrónico en expansión ha acumulado grandes volúmenes de datos sobre sus clientes. Sin embargo, su estrategia de marketing sigue siendo homogénea: todos los usuarios reciben las mismas promociones. El área de analítica busca implementar una estrategia de segmentación inteligente, identificando distintos tipos de clientes según su comportamiento, valor y satisfacción.

El desafío es que los datos muestran patrones contradictorios: algunos clientes compran mucho pero devuelven productos, otros navegan constantemente pero no compran, y otros tienen alta satisfacción pero bajo gasto.

Los datos recopilados son los siguientes:

Variable	Tipo	Unidad	Descripción
frecuencia	numérica	compras/mes	Número de compras mensuales
gasto	numérica	USD/compra	Monto promedio por compra
visitas	numérica	visitas/mes	Número de visitas al sitio
devoluciones	numérica	conteo/mes	Número de devoluciones
satisfaccion_cliente	numérica	escala 1–5	Nivel de satisfacción percibida
valor_cliente	numérica	USD/mes	Valor total del cliente (frecuencia × gasto)
cliente_premium	categorica (binaria)	True/False	Cliente de alto valor (percentil >70)

5. Datos Medio Ambiente

“Monitoreo y gestión de la calidad del aire”

Una agencia ambiental ha desplegado una red de sensores para monitorear la calidad del aire en distintas zonas de una ciudad. Los datos se utilizan para emitir alertas ambientales y diseñar políticas públicas.

Sin embargo, la interpretación de estos datos no es trivial: algunas zonas presentan altos niveles de ozono pero bajos niveles de material particulado, mientras que otras muestran el patrón inverso. Además, factores como el viento y el tráfico interactúan de manera compleja.

Variable	Tipo	Unidad	Descripción
pm25	numérica	$\mu\text{g}/\text{m}^3$	Partículas finas ($\leq 2.5 \mu\text{m}$)
no2	numérica	ppb	Dióxido de nitrógeno
trafico	numérica	índice (0–100)	Intensidad de tráfico vehicular
viento	numérica	m/s	Velocidad del viento
contaminacion	numérica	índice compuesto	Nivel agregado de contaminación
alerta	categorica (binaria)	True/False	Nivel crítico (percentil >70)